Movie Sentiment Analysis

Natural Language Processing | STT Terpadu Nurul Fikri

Adinda · Angeliq · Safira · Farhan · Randy

Problem Definition

The Challenge

Volume ulasan film digital yang masif membuat analisis opini manual menjadi tidak efisien dan memakan waktu.

The Solution

Mengimplementasikan NLP dan Machine Learning untuk mengklasifikasikan sentimen secara otomatis dan akurat.

Dataset: IMDB 50K

50,000 Reviews

Kumpulan data ulasan film yang bersumber dari platform Kaggle.

Binary Labels

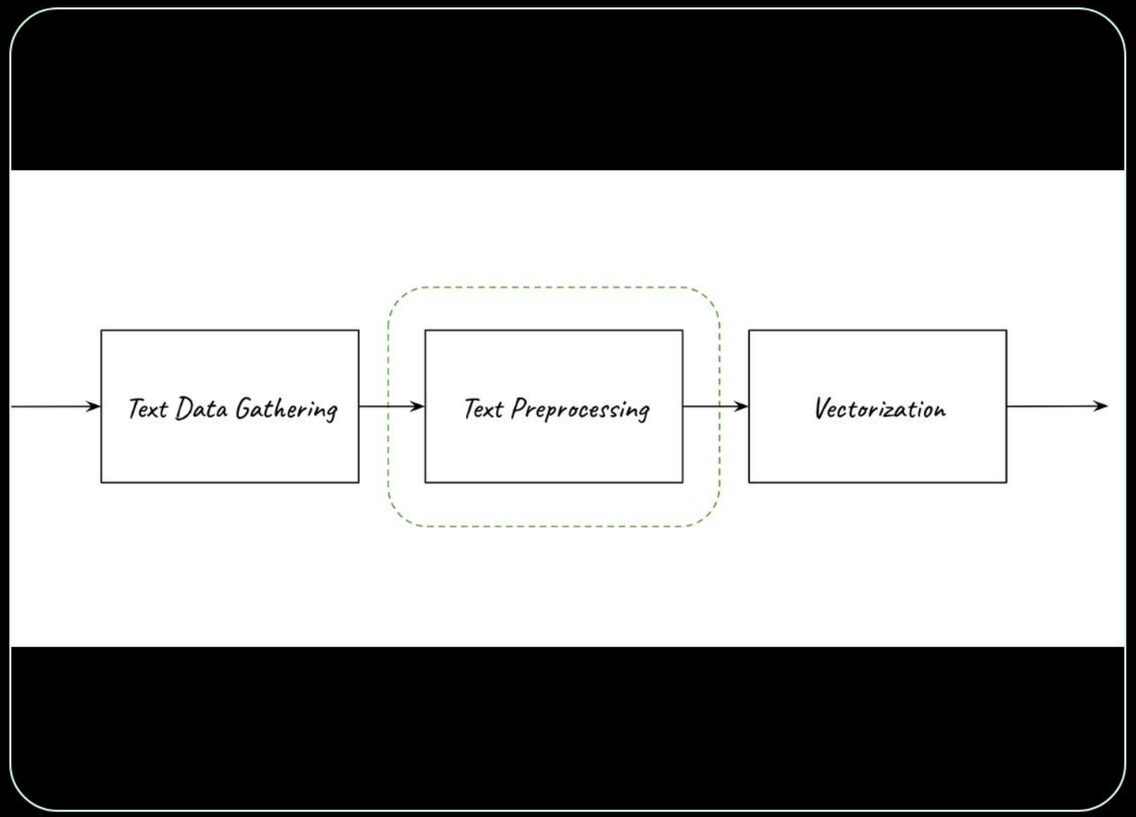
Label klasifikasi yang seimbang antara Positive dan Negative.

English

Menggunakan bahasa Inggris sebagai benchmark standar riset NLP.

Text Preprocessing

- → **Case Folding:** Menyeragamkan teks ke lowercase.
- → **Cleaning:** Menghapus tag HTML, angka, dan simbol.
- → **Tokenization:** Memecah teks menjadi unit kata.
- → **Stopword Removal:** Menghapus kata umum (the, is, and).
- → **Lemmatization:** Mengubah kata ke bentuk dasarnya.



Feature Extraction

TF-IDF

Mengukur tingkat kepentingan kata berdasarkan statistik frekuensi kemunculan dalam dokumen.

Berbasis Frekuensi

Word2Vec

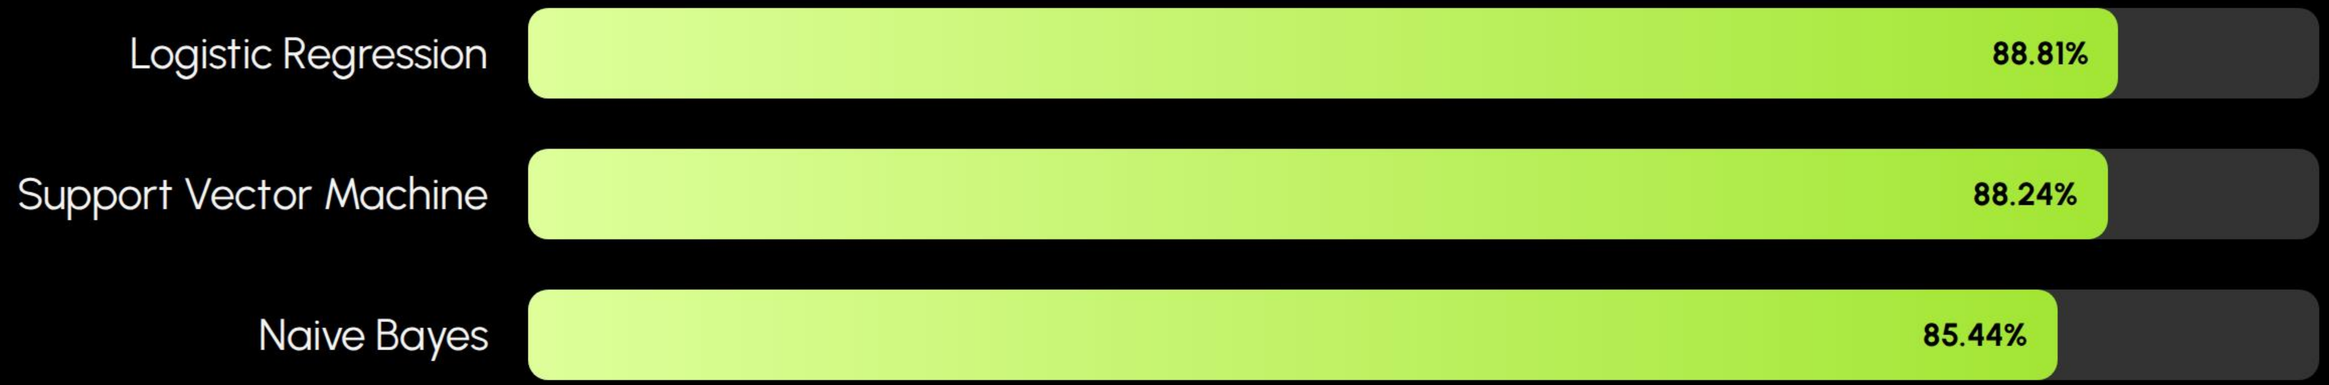
Representasi kata dalam bentuk vektor numerik yang menangkap hubungan semantik antar kata.

Berbasis Konteks

Modeling Phase

Algorithms: Naive Bayes, Logistic Regression, and SVM

Accuracy Benchmark (TF-IDF)



Model **Logistic Regression** menunjukkan performa paling stabil dan optimal.

The Winner Model

88.8%

Logistic Regression + TF-IDF

Kombinasi ini menghasilkan akurasi tertinggi dibandingkan skenario lainnya.

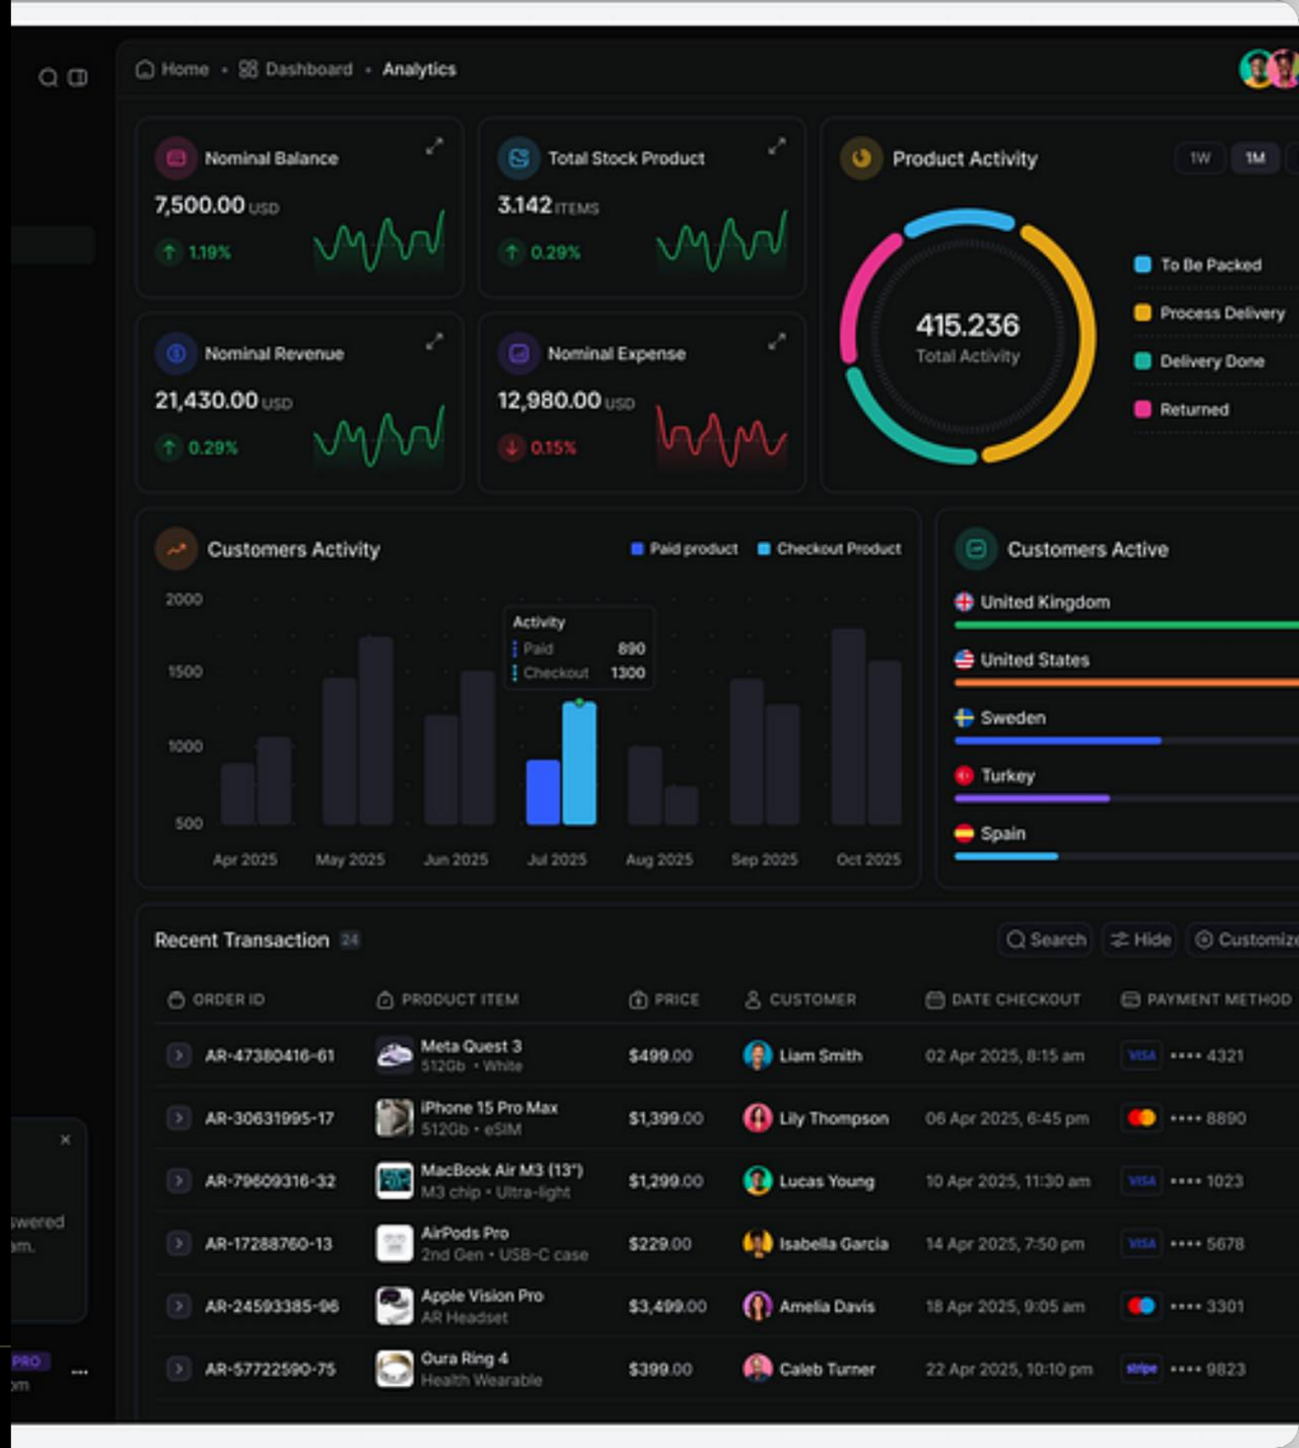
- → Efektif menangkap kata kunci sentimen.
- → Proses pelatihan relatif cepat.
- → Interpretasi hasil yang lebih stabil.

System Deployment

Gradio Interface

Model diintegrasikan ke dalam antarmuka web interaktif yang memungkinkan prediksi real-time.

Pengguna dapat memasukkan teks ulasan dan mendapatkan label sentimen secara instan.



Key Insights

TF-IDF Power

Pendekatan statistik masih sangat kuat untuk dataset movie reviews berskala besar.

Language Bias

Model saat ini terbatas pada Bahasa Inggris; butuh penyesuaian untuk ulasan Bahasa Indonesia.

Future BERT

Peluang menggunakan model Transformer (BERT) untuk menangkap konteks yang lebih dalam.

Conclusion

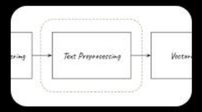
- → NLP dan Machine Learning efektif mengotomatisasi analisis sentimen opini publik.
- → Preprocessing adalah fondasi krusial yang menentukan kualitas fitur teks.
- → Logistic Regression dengan TF-IDF memberikan keseimbangan akurasi dan efisiensi terbaik.
- → Deployment via Gradio membuktikan nilai guna praktis dari model yang dikembangkan.

Thank You

Any Questions regarding the Project?

Sekolah Tinggi Teknologi Terpadu Nurul Fikri | 2026

Image Sources



https://miro.medium.com/v2/resize:fit:1400/1*7u1eQE6ELpQbvELs0aRqzg.png

Source: pub.towardsai.net



https://cdn.dribbble.com/userupload/43507873/file/original-6ccde408dbd36f1544fab618c6130f40.png?resize=752x&vertical=center

Source: dribbble.com
